

Текст для докладчика к Слайду 1

Коллеги! Мы провели кластеризацию пациентов и получили три группы. Теперь нам нужно ответить на ключевой вопрос: а не случайны ли эти различия? Может быть, если бы мы взяли другую выборку пациентов, кластеры «перемешались» бы?

Для ответа на этот вопрос мы используем аппарат проверки статистических гипотез. Мы формулируем альтернативные гипотезы H_1 — утверждения о том, что различия действительно существуют. Затем с помощью статистических тестов мы проверяем, можем ли мы отвергнуть нулевую гипотезу (что различий нет)

Текст для докладчика к Слайду 2

Коллеги! Давайте объясним, зачем мы вообще это делаем и почему выбрали именно такие гипотезы. Цели нашего анализа чисто статистические: проверить значимость различий, обосновать, что кластеризация имеет смысл, подтвердить, что наши признаки работают, и исключить случайность.

Теперь — почему мы выдвигаем именно эти четыре гипотезы? Они не взяты с потолка, а напрямую следуют из предыдущих двух докладов.

Первое. В докладе, где мы делали feature engineering и SHAP-анализ, мы выяснили, что тренды давления — это самые важные признаки. Они дают почти 40 процентов предсказательной силы модели. Следовательно, мы обязаны проверить гипотезы о том, что тренды САД и ДАД действительно различаются между кластерами. Если эта гипотеза не подтвердится — значит, наши самые важные признаки не работают, и вся кластеризация под вопросом.

Второе. В том же докладе мы обнаружили парадокс: кластер 3 — это пациенты с низким риском осложнений, но у них давление растет. А кластер 2 — это средний риск, но у них давление активно снижается. Возникает вопрос: а действительно ли эти две группы разные по динамике? Или это случайность? Поэтому мы формулируем гипотезу: кластер 2 отличается от кластера 3 по тренду САД. Это проверка самого интересного и неожиданного результата предыдущего этапа.

Текст для докладчика к Слайду 3

Теперь коротко о методах, которые мы использовали.

Первый шаг — мы проверили нормальность распределения с помощью теста Шапиро-Уилка. Это важно, потому что от этого зависит, какие тесты мы можем применять. При $p < 0.05$ данные считаются ненормальными.

Далее мы использовали ANOVA — анализ дисперсии. Этот метод отвечает на вопрос: есть ли вообще различия между тремя кластерами? Если $p < 0.05$ — различия есть.

Затем мы провели попарное сравнение с помощью t-test — сравнивали кластер 1 с кластером 2, 1 с 3, 2 с 3.

И самое важное — мы применили поправку Бонферрони. Почему? Потому что чем больше сравнений мы делаем, тем выше вероятность случайно найти «значимый» результат. Мы делим стандартный порог 0.05 на 3 сравнения и получаем $\alpha = 0.0167$. Только p-value меньше этого порога мы считаем действительно значимыми.

Текст для докладчика к Слайду 4

Переходим к результатам.

Первое: проверка нормальности показала, что распределение трендов давления во всех трёх кластерах отличается от нормального — $p = 0.0000$. Это не проблема: при больших выборках t-test и ANOVA устойчивы к нарушению нормальности.

Второе и главное: ANOVA для всех трёх признаков дала p-value меньше 0.05. Это значит, что различия между кластерами статистически значимы на уровне 95% доверительной вероятности. Самый сильный результат — у тренда САД: $F = 14.538$, $p < 0.0001$.

Для нас это подтверждение, что наши признаки действительно разделяют данные на три кластера, и это не случайность.

Текст для докладчика к Слайду 5

Теперь посмотрим на попарные сравнения. Здесь интересная картина — разные признаки показывают разный паттерн различий.

Для тренда САД мы видим, что кластер 2 значимо отличается от обоих других, а кластеры 1 и 3 между собой не различаются. Это повторяет наш предыдущий вывод из SHAP-анализа: тренд САД — самый сильный признак.

Для тренда ДАД единственное значимое различие — между кластером 2 и кластером 3. Различие между 1 и 2 находится на грани значимости: $p = 0.0539$ — чуть выше нашего скорректированного порога.

Для вариабельности САД мы видим значимое различие только между кластером 1 и 2. Гипотеза о том, что вариабельность в кластере 2 выше, чем в кластере 3, не подтвердилась — $p = 0.1583$.

Важно понимать: эти различия в паттернах — нормальное явление. Разные статистические тесты на разных признаках могут давать разные результаты. Главное — общий вывод: кластеры статистически различимы.

Текст для докладчика к Слайду 6

Сведём всё в итоговую таблицу.

Из пяти сформулированных альтернативных гипотез мы подтвердили четыре. Тренды и САД, и ДАД значимо различаются между кластерами. Кластер 2 значимо отличается от кластера 3 по тренду САД.

Не подтвердилась только гипотеза о том, что вариабельность в кластере 2 выше, чем в кластере 3. Фактически вариабельность в этих двух кластерах оказалась практически одинаковой: 12.68 против 12.82, $p = 0.1583$.

Можем сделать вывод, это успешная валидация. Наша кластеризация и наши признаки (особенно тренды) имеют статистическое обоснование. Мы можем быть уверены, что различия между кластерами — не артефакт выборки, а реальная структура данных.

Текст для докладчика к Слайду 7

В завершение — про ограничения и дальнейшие шаги.

Первое ограничение — ненормальность данных. Мы это учли и использовали t-test, который при больших выборках (а у нас больше 7000 пациентов) устойчив к нарушению нормальности. Но для чистоты эксперимента можно было бы использовать непараметрические аналоги.

Второе — поправка Бонферрони. Она консервативна, то есть может не заметить реальные различия. Это сознательный выбор в пользу строгости.

Что мы можем сделать дальше? Во-первых, повторить анализ с непараметрическими тестами для подтверждения. Во-вторых, построить ROC-кривые, чтобы оценить, насколько хорошо наши признаки разделяют кластеры. В-третьих, обучить классификатор, который по признакам предсказывает кластер пациента. И, наконец, провести кросс-валидацию, чтобы убедиться в устойчивости результатов на разных подвыборках.

Спасибо за внимание! Я готов ответить на вопросы.