

Исследование алгоритмов оценки состояния
объекта по данным временных рядов
на примере кардиомониторирования



Постановка задачи и актуальность

Гипертонический криз — внезапное критическое повышение давления, ведущее к инсульту, инфаркту или смерти. Кризу предшествуют изменения паттернов давления за **1–2 недели**.

Цель

По 14 дням измерений АД предсказать вероятность криза в ближайшие 7 дней

Целевая метрика

Macro F1 ≥ 0.85 — сбалансированное качество для обоих классов

Гипотеза H₀

Модель анализа временных рядов предсказывает кризы с Macro F1 > 0.85

Гипотеза H₁₃

SHAP-анализ выявляет клинически интерпретируемые предикторы

Исходные данные

Данные предоставлены в рамках федерального проекта «**Персональные медицинские помощники**». Период наблюдения: ноябрь 2023 — декабрь 2024. Все данные обезличены.

11 739

Пациентов

19 субъектов РФ, 119 медорганизаций

4.9M

Записей измерений

САД, ДАД, ЧП, временная метка

1.24M

Клинических событий

Дата, время, код события

23 798

Записей о терапии

Медикаментозное лечение пациентов

EDA: Качество данных и очистка

Физиологические выбросы

Менее 0.01% (435 записей) — исключены по клинически обоснованным границам.

Дубликаты

Удалено ~78 тыс. записей — одинаковые измерения одного пациента в одну секунду.

Часовые пояса

5 часовых поясов. Доля ночных измерений: **42.9% → 14%** после коррекции.

Пропуски

Рост/вес у 45% — медианная импутация по стратам.
Диагнозы у 60% — заменены специальными строками «Не указано» / «Нет данных».





EDA: Распределение давления

Распределение показателей

Показатель	Среднее	Медиана
САД	127.5 мм рт.ст.	126
ДАД	79.9 мм рт.ст.	79

Корреляция САД и ДАД равна 0.57

Вывод: кризы происходят даже при нормальных средних — ключевую роль играет динамика.






Кластеризация GDTW

Цель: выделить группы пациентов со схожей динамикой АД для персонализации наблюдения.

Почему GDTW?




GDTW явно учитывает время через штрафную функцию, накладывая ограничения на «склейку» далеких точек.



Feature Engineering и SHAP-анализ

Цель: Понять, какие клинические факторы определяют принадлежность пациента к тому или иному кластеру риска.

Какие признаки мы создали: тренд давления (линейная регрессия), вариабельность давления, процент времени с гипертонией и гипотонией



Тренд анализ и проверка альтернативных гипотез

Методы анализа

- **Линейная регрессия** — расчёт тренда по временному ряду
- **Тест Шапиро-Уилка** — проверка нормальности
- **ANOVA** — различия между тремя кластерами
- **Попарный t-тест** с поправкой Бонферрони ($\alpha = 0.0167$)

Вывод: Кластеры статистически различны. Тренды давления — работающие признаки для разделения групп.

Результаты: 4 из 5 гипотез подтверждены

✓ ANOVA

Различия значимы по всем признакам ($p < 0.05$)

✓ Тренды САД и ДАД

Значимо различаются между кластерами

✓ Кластер 2 vs 3

Значимые различия по тренду САД ($p < 0.0001$)

✗ Вариабельность

Кластеры 2 и 3 не различаются ($p = 0.1583$)

Архитектура гибридной модели

Задача: по последним 14 дням (20 временных точек, шаг 3 дня)

предсказать гипертонический криз в ближайшие 7 дней.

1 **GRU + Attention**
Извлекает долгосрочные зависимости из временных рядов, устойчив к разреженным данным

2 **XGBoost**
Обучается на агрегированных признаках (тренды, вариабельность, TIR) и статике

3 **Адаптивный блендинг**
Для каждого кластера — свои веса смешивания и порог бинаризации

Разброс весов подтверждает необходимость персонализации: для разных групп пациентов оптимальный баланс между временными и табличными признаками принципиально различается.

Результаты и подтверждение гипотез

Тестирование на **6 132 окнах** (20% пациентов, стратификация по кластерам).

Гипертонический криз

Precision 0.87 · Recall 0.87 · **F1 = 0.87**

Стабильные пациенты

Precision 0.83 · Recall 0.82 · **F1 = 0.83**

Macro F1 = 0.8512

Целевой порог 0.85 **достигнут**



Но подтверждена

Macro F1 > 0.85 достигнут



H13 подтверждена

SHAP выявил клинически значимые предикторы

Почему ML, а не классическая статистика?

Ограничения классических методов

Логистическая регрессия

Предполагает независимость наблюдений — нарушается из-за автокорреляции в рядах АД

Пороговый классификатор

САД > 140 → F1 = 0.52, почти случайное угадывание

Что дал ML

→ Тренды в 2.5× важнее

Чем любые агрегированные статистики

→ GRU + Attention

Автоматически извлекли временные зависимости

→ Ансамбль NN + XGBoost

Компенсировал слабости каждого алгоритма

→ Персонализация

+0.005 к Macro F1 за счёт кластеризации

ML не заменяет статистику, а расширяет её — гипотезы проверяются ANOVA/t-test, но прогнозирование учитывает нелинейность, автокорреляцию и взаимодействия признаков.