

СЛАЙД 1 — ТИТУЛЬНЫЙ

ИССЛЕДОВАНИЕ АЛГОРИТМОВ ОЦЕНКИ СОСТОЯНИЯ ОБЪЕКТА ПО ДАННЫМ ВРЕМЕННЫХ РЯДОВ НА ПРИМЕРЕ КАРДИОМОНИТОРИРОВАНИЯ

СЛАЙД 2 — ПОСТАНОВКА ЗАДАЧИ И АКТУАЛЬНОСТЬ

Гипертоническая болезнь — одно из самых распространённых сердечно-сосудистых заболеваний. Её самое опасное проявление — гипертонический криз — внезапное, критическое повышение давления, которое может привести к инсульту, инфаркту или смерти.

Ключевая проблема: Криз часто наступает внезапно, но ему предшествуют изменения в паттернах давления за 1–2 недели.

Цель исследования: Разработать модель, которая по 14 дням ежедневных измерений артериального давления предсказывает вероятность гипертонического криза в ближайшие 7 дней.

Целевая метрика: Macro F1 ≥ 0.85 (сбалансированное качество для обоих классов).

Основная гипотеза H0: Модель интеллектуального анализа временных рядов способна предсказывать критические состояния с Macro F1 > 0.85 .

Дополнительная гипотеза H13: SHAP-анализ выявляет клинически интерпретируемые предикторы, соответствующие медицинским протоколам.

СЛАЙД 3 — ИСХОДНЫЕ ДАННЫЕ

Данные предоставлены в рамках федерального проекта «Персональные медицинские помощники».

Ключевые параметры датасета согласно сопроводительной документации:

11 739 пациентов.

19 субъектов Российской Федерации.

119 медицинских организаций.

4 888 853 записи первичных измерений. Каждая запись содержит: систолическое артериальное давление, диастолическое артериальное давление, частоту пульса, временную метку измерения.

1 243 036 записей клинически значимых событий (КЗС). Каждая запись содержит: идентификатор пациента, дату и время формирования события, код события.

23 798 записей о медикаментозной терапии.

Период наблюдения: ноябрь 2023 – декабрь 2024.

Все данные обезличены. Идентификация пациентов, медицинских организаций и субъектов выполнена через отдельные справочные файлы.

СЛАЙД 4 — EDA: КАЧЕСТВО ДАННЫХ И ОЧИСТКА

Первый этап — тщательная проверка качества данных.

Физиологические выбросы: менее 0.01% (всего 435 записей из 4.9 млн) — исключены. Для определения выбросов были заданы жесткие клинически обоснованные границы для каждого физиологического параметра.

САД (систолическое АД): < 40 мм рт.ст. (несовместимо с жизнью) или > 250 мм рт.ст. (предел, за которым измерение не имеет смысла).

ДАД (диастолическое АД): < 30 мм рт.ст. или > 150 мм рт.ст., а также любые случаи, где $ДАД > САД$ (физиологически невозможно).

ЧП (частота пульса): < 30 ударов/мин (глубокая брадикардия) или > 220 ударов/мин (предел для взрослых).

Возраст: < 18 лет (не целевая аудитория) или > 120 лет (невозможно).

Дубликаты: обнаружено и удалено около 78 тысяч дублирующихся записей. Дубликатом считались две и более записи измерения давления, сделанные одним и тем же пациентом в одну и ту же секунду.

Часовые пояса: выявлено 5 различных часовых поясов. До коррекции доля ночных измерений составляла 42.9%. После приведения к локальному времени — снижение до 14%.

Пропуски в антропометрии:

- Рост и вес отсутствовали у 45% пациентов — импутация. Использовалась медианная импутация по стратам — пациенты разделялись на группы по комбинации "группа наблюдения" + "возрастная группа", для каждой группы вычислялись медианы роста и веса, и этими медианами заполнялись пропуски.

- Диагнозы отсутствовали у 60% пациентов — специальные методы импутации. Все пропуски в полях 'основное заболевание' и 'сопутствующие заболевание' были заменены на специальные строки: 'Не указано' и 'Нет данных' соответственно.

СЛАЙД 5 — EDA: РАСПРЕДЕЛЕНИЕ ДАВЛЕНИЯ

Распределение показателей после очистки:

Показатель / Среднее / Медиана / Норма

Систолическое АД (САД) / 127.5 мм рт.ст. / 126 / Целевой уровень

Диастолическое АД (ДАД) / 79.9 мм рт.ст. / 79 / В пределах нормы

Корреляция САД и ДАД: $r = 0.57$ (умеренная положительная связь, ожидаемо).

Важный вывод: Большинство пациентов достигают целевых уровней давления, но кризы всё равно происходят — значит, ключевую роль играет динамика, а не средние значения.

СЛАЙД 6 — КЛАСТЕРИЗАЦИЯ ВРЕМЕННЫХ РЯДОВ (GDTW)

Цель данного этапа - Выделить группы пациентов со схожей динамикой АД для персонализации наблюдения.

Почему GDTW?

В медицинских данных измерения привязаны к неравномерным визитам. Классический DTW игнорирует реальные даты, работая с индексами точек. Наш GDTW явно учитывает время через штрафную функцию, накладывая ограничения на «склейку» далеких точек. Это позволяет различать схожие по форме кривые, но разные по времени развития события.

Результат — 3 кластера пациентов:

- Кластер 1 (n=815, K3C=243): Нестабильные. Высокая амплитуда колебаний. Частые кризы, высокий риск.
- Кластер 2 (n=4200, K3C=109): Стабильные. Минимальные колебания. Эффективная регуляция давления, наименьший риск.
- Кластер 3 (n=2374, K3C=171): Промежуточные. Умеренная амплитуда, прослеживается цикличность. Умеренный риск.

Вывод: Разделение клинически значимо. Выделенные паттерны (нестабильный, стабильный, умеренный) позволяют персонализировать предсказания для каждого типа пациентов.

СЛАЙД 7 — FEATURE ENGINEERING: СОЗДАНИЕ ПРИЗНАКОВ

Цель: Понять, какие клинические факторы определяют принадлежность пациента к тому или иному кластеру риска.

Какие признаки мы создали:

1. Тренд давления (линейная регрессия): показывает скорость и направление изменения артериального давления за весь период наблюдения.
2. Вариабельность давления: размах колебаний давления, отражающий нестабильность состояния пациента.
3. Процент времени с гипертонией и гипотонией: доля дней, когда давление выходило за целевые границы.

Важно: Время наблюдения и количество измерений сознательно исключены — они учтены в методе кластеризации.

Как мы интерпретируем важность признаков — метод SHAP:

Длина полосы на графике показывает, насколько признак важен для модели.

Красный цвет (положительные значения) означает, что признак увеличивает вероятность попадания пациента в этот кластер.

Синий цвет (отрицательные значения) означает, что признак уменьшает вероятность попадания в этот кластер.

Что показывает анализ по кластерам:

Кластер 1 (высокий риск, 11 процентов пациентов): нет доминирующих признаков. Пациенты очень разнородны, требуют индивидуального анализа.

Кластер 2 (средний риск, 57 процентов пациентов): тренды давления имеют отрицательные значения. Это ключевой маркер: давление снижается, терапия эффективна.

Кластер 3 (низкий риск, 32 процента пациентов): тренды давления имеют положительные значения. Парадокс: риск осложнений низкий, но давление растет. Требуется особого внимания.

Вывод: динамика давления вносит вдвое больший вклад, чем любые агрегированные статистики. Это подтверждает решение использовать последовательные модели (GRU), а не только табличные признаки.

СЛАЙД 8 — ТРЕНД-АНАЛИЗ И ПРОВЕРКА АЛЬТЕРНАТИВНЫХ ГИПОТЕЗ

Цель этапа:

Проверить, являются ли различия между кластерами статистически значимыми, и подтвердить, что выделенные признаки (тренды, вариабельность) действительно разделяют группы, а не возникли случайно.

Используемые методы:

- Линейная регрессия для расчета тренда (наклон) по временному ряду каждого пациента.
- Тест Шапиро-Уилка для проверки нормальности распределения.
- ANOVA для проверки наличия различий между тремя кластерами в целом.
- Попарный t-тест с поправкой Бонферрони ($\alpha = 0.0167$) для сравнения кластеров между собой и исключения ложноположительных результатов при множественных сравнениях.

Альтернативные гипотезы (H_1):

1. Тренды САД различаются между кластерами.
2. Тренды ДАД различаются между кластерами.
3. Вариабельность САД различается между кластерами.

4. Кластер 2 отличается от кластера 3 по тренду САД.
5. Вариабельность в кластере 2 выше, чем в кластере 3.

Что подтвердилось:

- ANOVA: различия между кластерами значимы по всем трем признакам ($p < 0.05$). Кластеризация имеет смысл.

- Тренды САД и ДАД значимо различаются между кластерами.

- Кластер 2 значимо отличается от кластера 3 по тренду САД ($p < 0.0001$).

Что не подтвердилось:

- Гипотеза о том, что вариабельность в кластере 2 выше, чем в кластере 3 ($p = 0.1583$). Фактически вариабельность в этих двух группах оказалась одинаковой.

Итог: из пяти проверенных гипотез подтвердились четыре. Кластеры статистически различны. Тренды давления — работающие признаки для разделения групп.

СЛАЙД 9 — АРХИТЕКТУРА ГИБРИДНОЙ МОДЕЛИ

Задача: по последним 14 дням наблюдения (окно из 20 временных точек, шаг дискретизации — 3 дня) предсказать, наступит ли гипертонический криз в ближайшие 7 дней.

Входные данные: нормализованные ряды САД, ДАД, ЧП + статические признаки (возраст, ИМТ, кластер).

Пайплайн обучения (3 этапа):

1. GRU + Attention. Обучается на временных рядах. Зачем: извлекает долгосрочные зависимости, устойчив к разреженным данным (визиты к врачу не ежедневные).
2. XGBoost. Обучается на агрегированных признаках (тренды, вариабельность, TIR) и статике. Зачем: табличные признаки дают ортогональную информацию, которую GRU может не уловить.
3. Адаптивный блендинг. Для каждого из трех кластеров отдельно подбираем веса смешивания (GRU vs XGBoost) и порог бинаризации.

Зачем: вклад временных и табличных признаков различается от кластера к кластеру — единая модель для всех была бы хуже.

Подобранные веса:

- Кластер 1 (высокий риск): 15% GRU, 85% XGBoost.
- Кластер 2 (средний риск): 69% GRU, 31% XGBoost.
- Кластер 3 (низкий риск): 82% GRU, 18% XGBoost.

Разброс весов подтверждает необходимость персонализации: для разных групп пациентов оптимальный баланс между временными и табличными признаками

СЛАЙД 10 — РЕЗУЛЬТАТЫ И ПОДТВЕРЖДЕНИЕ ГИПОТЕЗ

Финальное тестирование проведено на выборке из 6132 окон (20% пациентов, стратификация по кластерам).

Метрики по классам:

Стабильные: Precision 0.83, Recall 0.82, F1 0.83

Криз: Precision 0.87, Recall 0.87, F1 0.87

Macro F1 = 0.8512

Статус гипотез:

H0 (основная, целевой F1 > 0.85): ПОДТВЕРЖДЕНА.

H13 (SHAP выявляет значимые предикторы): ПОДТВЕРЖДЕНА.

СЛАЙД 11 — ПОЧЕМУ ML, А НЕ КЛАССИЧЕСКАЯ СТАТИСТИКА?

Теперь, когда мы показали результат, ответим на вопрос: почему эта задача не решается обычной статистикой?

Что не так с логистической регрессией: она предполагает линейную связь признаков с таргетом и независимость наблюдений. Во временных рядах АД измерения внутри одного пациента сильно автокоррелированы — нарушение независимости «съедает» p-value и делает доверительные интервалы несостоятельными.

Почему не работают простые пороги: если бы криз предсказывался по среднему САД > 140, мы бы не проводили это исследование. Мы обучили

такой «пороговый классификатор»: он дал $F1 = 0.52$ — почти случайное угадывание. Причина — нормальное среднее давление не гарантирует отсутствие криза; важны неявные паттерны (тренд, вариабельность, взаимодействия).

Что дал ML: тренды давления оказались в 2.5 раза важнее любых агрегированных статистик. GRU и Attention автоматически извлекли эти зависимости. Ансамбль NN+XGBoost скомпенсировал слабости каждого алгоритма. Персонализация по кластерам добавила ещё 0.005 к Macro F1.

Таким образом, ML не заменяет статистику, а расширяет её — мы по-прежнему проверяем гипотезы ANOVA/t-test, но саму задачу прогнозирования решаем методами, которые учитывают нелинейность, автокорреляцию и взаимодействия признаков.